

Modèle Skellam pour le targeter — choix et limites

1 Le modèle

Sur un créneau d'une heure, à une station, on note deux variables aléatoires à valeurs dans $\mathbb{N}$:

- N_{in} : nombre de vélos qui **arrivent** à la station ;
- N_{out} : nombre de vélos qui **en repartent**.

Hypothèses : $N_{\text{in}} \sim \text{Poisson}(\lambda_{\text{in}})$, $N_{\text{out}} \sim \text{Poisson}(\lambda_{\text{out}})$, et $N_{\text{in}}, N_{\text{out}}$ **indépendantes**.

La grandeur que le targeter cherche à anticiper est la **variation nette du stock** sur l'heure : $\Delta = N_{\text{in}} - N_{\text{out}}$. Comme différence de deux lois de Poisson indépendantes, Δ suit la **loi de Skellam** $(\lambda_{\text{in}}, \lambda_{\text{out}})$.

Les paramètres $\lambda_{\text{in}}, \lambda_{\text{out}}$ dépendent de **quatre variables explicatives** :

- la **station** ;
- l'**heure** $h \in \{0, \dots, 23\}$;
- le **type de jour** $\in \{\text{ouvré (lun-ven), week-end (sam-dim)}\}$;
- la **saison** $\in \{\text{froid (avant 20 mars 2026), tempéré (à partir)}\}$.

2 Justification du modèle

2.1 Pourquoi Poisson pour N_{in} et N_{out}

Les trois hypothèses caractéristiques d'un processus de Poisson sont qualitativement vérifiées :

- **événements rares** sur l'heure (< 10 mouvements/h/station typiquement) ;
- **inter-événements sans mémoire** (pas d'effet de groupe à grande échelle) ;
- **taux λ stable** dans la fenêtre d'une heure.

Conditions valides en régime non saturé (station ni vide ni pleine).

2.2 Pourquoi N_{in} et N_{out} indépendantes

Déposer un vélo et en retirer un sont deux décisions individuelles décorréées. La corrélation n'apparaît qu'aux **saturations** : un usager ne peut pas déposer sur une station pleine, donc forcer la station vers le plein bloque mécaniquement les arrivées suivantes.

2.3 Pourquoi conditionner sur le type de jour et la saison

Vérification empirique sur les ≈ 90 jours scrappés (cf. `src/targeter/render.py`) :

- **ouvré vs week-end** : pic matinal 8h marqué en semaine, absent le week-end ; profils horaires nettement distincts.
- **froid vs tempéré** : demande tempérée $\approx +60\%$ par rapport au froid, à type de jour fixé.

Coupure froid/tempéré au **20 mars 2026** : équinoxe de printemps, repère astronomique neutre, sans biais de calendrier.

Croiser donne $2 \times 2 = 4$ strates de 10 à 40 jours chacune. Ajouter une 5^e variable (vacances, jour précis) ferait passer certaines strates sous 5 jours et dégraderait la précision de λ .

3 Limites

1. **Période courte.** ≈ 90 jours seulement (février $\rightarrow$ mai 2026). Aucune couverture estivale ni automnale ; aucune année complète pour observer les cycles annuels.
2. **Coupure climatique brutale.** Le 19 et le 21 mars sont en pratique quasi-identiques mais classés dans des saisons différentes — c’est une approximation grossière d’un passage progressif.
3. **Pas de météo locale.** Un mardi tempéré sous pluie battante est prédit comme un mardi tempéré ensoleillé, alors que la demande peut chuter d’un facteur 2 sous la pluie.
4. **Vacances scolaires non modélisées.** Effet visible mais données insuffisantes pour les caractériser comme une 5^e dimension du découpage.
5. **Stations saturées (censure).** Quand une station est régulièrement pleine, certains *ARRIVAL potentiels* n’apparaissent pas dans la base (l’usager ne peut physiquement pas déposer) ; λ_{in} y est mécaniquement sous-estimé. Effet à corriger spécifiquement pour les stations chroniquement saturées.
6. **Indépendance des heures.** λ_h et λ_{h+1} sont estimés séparément, sans tirer parti de la continuité naturelle de la demande au cours de la journée. Un lissage (noyau gaussien sur h , spline) gagnerait en précision sur les strates peu peuplées.